

# Impacto de valores extremos na imputação múltipla de dados faltantes com MICE no R

Enzo Porto Brasil (Universidade de Brasília)  
E-mail: enzoportobrasil@gmail.com



## 1. INTRODUÇÃO

Dados faltantes continuam sendo um desafio recorrente em bases empíricas e, quando ignorados, podem distorcer estimativas e comprometer a validade de inferências. A imputação múltipla (IM) oferece uma abordagem estatisticamente robusta, mas seu desempenho pode ser fortemente afetado pela presença de valores extremos, que tendem a distorcer distribuições preditivas e ampliar o risco de viés. Com base em extensas simulações de Monte Carlo, este estudo avalia o comportamento de diferentes métodos de IM (paramétricos, doadores e baseados em *machine learning*) em cenários com e sem contaminação por valores extremos.

Os resultados evidenciam padrões persistentes de viés direcional nos coeficientes estimados e uma troca sistemática entre estabilidade preditiva e fidelidade inferencial. Assim, esta pesquisa fornece evidências de que a escolha do método de imputação deve considerar de forma integrada o mecanismo de ausência de dados e a influência de valores extremos.

## 2. MATERIAIS e MÉTODOS

### 2.1 Desenho geral

- Cenários pareados: dados limpos (OLS) vs dados contaminados (Elastic Net);
- Faltantes em apenas em uma variável. Mesmas dobras de validação cruzada reutilizadas em todas as imputações e métodos;
- **Objetivo:** isolar o efeito de valores extremos e da imputação no desempenho preditivo e inferencial.

### 2.2 Geração dos dados

- Três variáveis contínuas ( $y$ ,  $x_1$ ,  $x_2$ ) com estrutura Gaussiana e correlação controlada entre  $x_1$  e  $x_2$  ( $\rho = 0$  ou  $0.6$ );
- Dois conjuntos por cenário: baseline (dados limpos) e contaminado.

### 2.3 Contaminação (com valores extremos)

- Mecanismo *casewise*, simétrico, “ $\pm 3$  s” aplicado a ( $y$ ,  $x_1$ ,  $x_2$ ) com proporção:  $P_{\text{ext}} \in \{0.03; 0.04; 0.05; 0.10; 0.15; 0.30\}$ ;
- Gera outliers verticais e pontos de alavancagem.

### 2.4 Dados faltantes (Missing Completely at Random - MCAR)

- Induzidos apenas em  $x_2$ , com  $P_{\text{miss}} \in \{0.05; 0.10; 0.25; 0.30\}$ ;
- Matriz preditora “congenita” para imputar  $x_2$ , com base em ( $y$ ,  $x_1$ ).

### 2.5 Métodos de imputação (pacote MICE no R)

- **Paramétricos:** T1 `norm.predict`, regressão linear determinística (sem incerteza); T2 `lasso.select.norm`, regressão normal com seleção Lasso (esparsidade); e T3 `norm.boot`, regressão normal com reamostragem bootstrap.
- **Doadores / Machine Learning:** T4 `pmm`, Predictive Mean Matching com valores observados mais próximos; T5 `rf`, *Random Forest* (árvores de regressão não paramétricas); e T6 `midastouch`, PMM com seleção ponderada de doadores.

### 2.6 Modelos de análise (pós-imputação)

- Dados limpos: regressão linear, OLS;
- Dados contaminados com extremos: regressão lasso, Elastic Net (EN): com  $\alpha = 0.5$  e  $\lambda$  por validação cruzada.

### 2.7 Avaliação (métricas principais)

- Predição (primária): CV-MSE (média, variância, quantis);
- Inferência: viés, RMSE e cobertura 95% de  $(\beta_0, \beta_1, \beta_2)$  via regras de Rubin.
- Calibração: densidades/boxplots de CV-MSE e curvas QQ ( $Y$  predito vs  $Y$  verdadeiro).


### 2.8 Outros fatores do estudo (grid)

- Replicações de Monte Carlo:  $n_{\text{sim}} \in \{50; 300; 1000; 3000\}$ ;
- Número de imputações simuladas por cenário:  $M \in \{5; 10\}$ .
- Ramos de análise: {limpo/OLS, contaminado/EN}  $\times$  métodos de imputação T1-T6.


### 2.9 Reprodutibilidade e comparabilidade

- Única semente aleatória para garantir reprodutibilidade dos resultados;
- As partições de validação cruzada foram mantidas iguais em todos os métodos dentro de cada simulação, assegurando comparações pareadas e justas;
- A ordem dos métodos (T1--T6) foi mantida constante nas figuras e tabelas.

## 3. RESULTADOS



**Figura 1.** Exemplo da relação entre as variáveis (mapa de correlação, histogramas marginais e densidades empíricas) para o conjunto de dados limpos e contaminados, respectivamente, com  $n = 500$ ,  $P_{\text{ext}} = 0.10$  e  $\rho = 0.6$ . Os eixos representam  $y$ ,  $x_1$  e  $x_2$ .



**Figura 2.** Densidades do Erro Quadrático Médio (EQM) (dados limpos vs. dados contaminados com extremos), boxplots de EQMs e gráficos QQ (quantis preditos vs. quantis verdadeiros de  $y$ ) para seis métodos de imputação múltipla (T1-T6) em diferentes cenários e considerando, respectivamente,  $n = 20$  e  $n = 500$ .

## 4. CONCLUSÃO

Extensas simulações mostraram que valores extremos impõem viés direcional persistente (intercepto aumenta e inclinações distorcidas). Aumentar  $n$  contrai a variância, não o viés. Para previsão estável, métodos paramétricos (T1-T3) manteve CV-MSE mais baixo e caudas mais curtas, inclusive com contaminação. Para inferência de inclinações sob alta falta de dados e contaminação, doadores/ML (T4-T6) atenuam viés e frequentemente melhoram a cobertura, ao custo de maior dispersão preditiva. Há um equilíbrio previsível entre estabilidade preditiva e fidelidade inferencial, moderado por tamanho amostral e proporção de dados faltantes. Os resultado indicam que a escolha do método deve refletir o objetivo analítico e a presença de extremos.

### REFERÊNCIAS

- [1] HASTIE, Trevor; TIBSHIRANI, Robert; WAINWRIGHT, Martin. **Statistical learning with sparsity**. Monographs on statistics and applied probability, v. 143, n. 143, p. 8, 2015.
- [2] Kotz S, Nadarajah S (2000). **Extreme value distributions: theory and applications**. world scientific.
- [3] NETER, John et al. **Applied linear statistical models**. 1996.
- [4] Rubin D, Wiley J (1987). "New York Chichester Brisbane Toronto Singapore S." **Multiple imputation for nonresponse in surveys**.
- [5] van Buuren S, Groothuis-Oudshoorn K (2011). "mice: Multivariate Imputation by Chained Equations in R." *Journal of Statistical Software*, 45(3), 1–67. doi:10.18637/jss.v045.i03.