

Técnicas de Imputação para Variáveis Dicotômicas

Enzo Porto Brasil;

Eduardo Yoshio Nakano

Departamento de Estatística, Universidade de Brasília

***Resumo:** este trabalho teve como objetivo investigar a importância das principais técnicas de imputação de dados faltantes dicotômicos, e exemplificar a relevância da recuperação de informações em um contexto real. Ilustrado por conjunto de dados reais, a ideia principal foi destacar possíveis diferenças entre imputação com uso da medida central moda e uso da regressão logística, com foco maior na modelagem preditiva. Toda a análise foi fomentada com uso do software R (versão 4.0.2).*

1 Introdução

Em um planeta cada vez mais integrado, o acesso à informação se tornou fator principal e indispensável em estudos. Em contraponto, análises sem preparação adequada são capazes de gerar resultados tendenciosos, com possibilidade de serem divulgadas conclusões falsas e, assim, influenciar de forma negativa o pensamento científico (PROVOST; FAWCETT, 2013). Além disso, Nunes (2007) relata em sua tese que, durante diversos processos de pesquisa, a perda de material e dados é recorrente, e desconsiderar esse fato pode não ser a melhor forma de avaliar os resultados.

A frequente ausência de informações em um banco de dados pode, muitas vezes, ser alarmante à ciência, uma vez que a metodologia estatística é fundamentada para analisar dados completos, e assim o tema não deve ser ignorado por completo (HARRELL et al., 2015; RUBIN, 1996; KENWARD; CARPENTER, 2007). Em algumas situações a ocorrência de dados faltantes (*missings*) requer mais atenção, e assim a imputação desses valores pode ocorrer por métodos simples, como utilizar estatísticas descritivas, ou por técnicas mais sofisticadas, por meio de modelagem estatística. Este último caso, mais complexo, possibilita diferentes interpretações de resultados e conclusões robustas (MCKNIGHT et al., 2007).

O tipo de variável a ser imputada define o método matemático mais adequado para estimar os valores faltantes. Para o caso em que as variáveis são de natureza categórica dicotômica, ou seja, possuem apenas dois valores, a técnica de imputação pode ocorrer com uso da estatística moda (valor mais frequente) ou com uso de regressão logística (KUTNER et al., 2005; AGRESTI, 2007).

Portanto, este trabalho teve sobretudo o objetivo de investigar a importância das principais técnicas de imputação de dados faltantes dicotômicos, e exemplificar a relevância da recuperação de informações em um contexto real. Ilustrado por conjunto de dados reais referente aos caranguejos-ferradura, abordado no livro de Agresti (2007), a ideia principal foi destacar possíveis diferenças entre imputação com uso da medida central moda e uso da regressão logística, com foco na modelagem preditiva.

2 Metodologia

2.1 Banco de dados

O conjunto de dados utilizado na pesquisa compõe um exemplo real citado durante todo o livro Agresti (2007), onde contem variáveis referentes ao animal caranguejo-ferradura. Os dados são retratos de uma pesquisa realizada pela Universidade da Florida em 1996, e o estudo completo é descrito em (BROCKMANN, 1996).

A princípio, a ideia da investigação realizada pela Universidade foi estimar se existe caranguejos machos por perto, também chamados de satélites, com base em características de um caranguejo-ferradura fêmea encontrado, que são: coloração (4 cores), condição da coluna (3 tipos), tamanho da concha (em cm) e peso (em kg). Além disso, a base de dados contém a quantidade de caranguejos machos encontrados nas proximidades, para fins de conferência de resultados. Há 173 observações no conjunto de dados.

A variável de interesse estudada neste projeto indica se existe ou não ao menos um caranguejo macho nas proximidades. Ela tem natureza categórica, com resposta dicotômica (valor 1 para existência de ao menos um caranguejo macho nas proximidades; valor 0 para nenhum macho encontrado). À priori, o banco de dados não possui valores faltantes, mas foi induzido por simulações a apresentar diferentes proporções de *missings*, para por fim gerar resultados que possibilitem a comparação entre as técnicas de imputação apresentadas. Toda a análise foi fomentada com uso do software R (versão 4.0.2).

2.2 Modelo Preditivo

A fins de ilustração, foi utilizado o método de Regressão Linear para ajustar um modelo capaz de estimar o tamanho da concha do caranguejo-ferradura fêmea, com base nas demais características que ela apresenta, sendo uma das variáveis a indicação da presença ou não de ao menos um macho nas proximidades.

2.2.1 Regressão Linear Múltipla

O estudo sobre regressão é uma metodologia estatística que se baseia na análise da relação entre duas ou mais variáveis, de forma que uma variável resposta possa ser estimada a partir de uma ou mais variáveis explicativas. A característica da variável resposta indica quais técnicas de modelagem devem ser consideradas (KUTNER et al., 2005)

A Regressão Linear Múltipla é pautada na previsão de uma variável resposta, de natureza quantitativa discreta ou contínua, com base em mais de uma variável explicativa. Dessa forma, o modelo linear pode ser representado como na Equação 2.2.1 (RODRIGUES, 2012):

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \epsilon_i \quad (2.2.1)$$

Em que:

- Y_i : valor da variável resposta ou dependente na i -ésima observação, $i = 1, 2, \dots, n$;
- $\beta_0, \dots, \beta_k$: parâmetros da equação (coeficientes);
- $X_{1i}, X_{2i}, \dots, X_{ki}$: valores da i -ésima observação das k variáveis explicativas;
- ϵ_i : representa os erros aleatórios (resíduos), com distribuição $N(0, \sigma^2)$.

Os principais pressupostos necessários para a construção do modelo de Regressão Linear, conforme indicam Kutner et al. (2005) e Harrel (2015), são:

1. Linearidade entre as variáveis resposta e explicativa(s);
2. Independência dos erros (resíduos) das variáveis explicativas, ou seja, covariância igual a zero;
3. O erro deve ter distribuição $N(0, \sigma^2)$, média nula e variância constante (homoscedasticidade);
4. Para a regressão linear múltipla, as variáveis explicativas não devem ser correlacionadas, a evitar problemas de multicolinearidade;
5. Baixa exogeneidade, ou seja, erros de medidas não interferem nas variáveis explicativas.

Em situações onde a variável resposta apresenta diferentes padrões de variação e inconsistência nos pressupostos, em principal de normalidade e heterocedasticidade dos

resíduos, a transformação dessa variável pode ser útil para adequar o ajuste final do modelo. A mais conhecida seria a transformação de Box-Cox, sintetizada pela transformação (2.2.2), em que o parâmetro de potência λ pode ser sugerido com a finalidade de garantir adequação dos pressupostos (KUTNER et al., 2005):

$$y_{\lambda} = \begin{cases} \log(y), & \text{se } \lambda = 0 \\ \frac{y^{\lambda}-1}{\lambda}, & \text{se } \lambda \neq 0 \end{cases} \quad (2.2.2)$$

2.3 Estudo de Simulação

Algumas simulações foram feitas para exemplificar potenciais cenários de dados faltantes, e assim comparar resultados. Conforme mencionado, a base de dados original não apresenta *missings*, fator que possibilitou a comparação entre valores simulados e reais com facilidade.

Desse modo, os dados faltantes foram gerados de forma aleatória, e esse processo foi simulado 400 vezes, reproduzindo assim 400 possíveis conjuntos de informações. Ademais, para fins de comparação, cinco diferentes proporções de dados faltantes foram consideradas na análise, sendo elas: 1%, 5%, 10%, 20% e 40%. Por conseguinte, ao todo, para cada técnica de imputação, 2000 bases de dados foram simuladas com a presença de valores faltantes hipotéticos.

Para cada base de dados, um modelo de Regressão Linear foi obtido e ajustado para prever o comprimento da concha do caranguejo-ferradura fêmea. E, em cada situação, as duas técnicas de imputação de variáveis dicotômicas foram utilizadas (imputação pela Moda e imputação com Regressão Logística), para fins comparativos.

2.4 Imputação

Harrel et al. (2015) explicam que a metodologia estatística conhecida é formulada para avaliar conjunto de dados completos, e o tratamento correto de situações com presença de dados faltantes pode ser o diferencial ao concluir sobre determinado assunto.

Ao simular os dados faltantes para a variável qualitativa, que indica se existe ou não ao menos um caranguejo macho nas proximidades (presente no modelo preditivo de Regressão Linear), a primeira técnica de recuperação desses *missings* ocorreu com a imputação pela estatística descritiva moda. A segunda técnica foi direcionada pela análise de Regressão Logística Dicotômica (AMBLER; OMAR; ROYSTON, 2007).

A imputação dos dados faltantes se torna importante para o melhor ajuste possível do modelo de Regressão Linear, que é formulado para avaliação de dados completos, o

qual foi capaz de prever da forma mais adequada possível o tamanho da concha dos caranguejos-ferradura fêmeas.

2.4.1 Imputação pela Moda

O processo de imputação pela moda depende apenas da variável que apresenta os valores faltantes. Com isso, após simulações, verificou-se para cada caso a quantidade de valores 0 e 1 nos dados restantes, e assim foi imputado o valor que aparece com maior frequência (NUNES, 2007; AMBLER; OMAR; ROYSTON, 2007). Por fim, os modelos de Regressão Linear finais foram ajustados com a presença dos valores imputados pela moda para a variável explicativa que indica a presença de ao menos um caranguejo macho nas proximidades (valor 1 para a presença de ao menos um caranguejo macho nas proximidades; e valor 0 para nenhum macho encontrado).

2.4.2 Imputação com Regressão Logística Dicotômica

As técnicas de imputação com uso de modelagem preditiva, como Regressão Logística, geram robustez e consistência nos resultados (BUCK, 1960). Agresti (2007) e Kutner (2005) apresentam a Regressão Logística Dicotômica como a previsão de variáveis respostas binárias, isto é, possuem apenas dois valores, usualmente orientados por ‘sucesso’ ou ‘fracasso’, com apoio de variáveis explicativas. Não há linearidade evidente na relação entre uma variável de resposta binária Y e variáveis explicativas X , portanto algumas adaptações devem ser ponderadas para o ajuste final do modelo.

A variável Y tem distribuição Bernoulli, com probabilidade de sucesso $P(Y = 1) = \pi$ e fracasso $P(Y = 0) = 1 - \pi$. Logo, a média será expressa por $E(Y) = \pi$ e a variância por $Var(Y) = \pi(1 - \pi)$. A fim de estimar valores no intervalo (0,1), tem-se definida a função de resposta logística (2.4.1):

$$E(Y_i|x_i) = \pi(x_i) = \frac{\exp(\alpha_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki})}{1 + \exp(\alpha_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki})} \quad (2.4.1)$$

E assim, utiliza-se a transformação logito (Equação (2.4.2)) como retrato conveniente da forma aditiva do modelo, que propõe uma apresentação linear. A interpretação para os coeficientes do modelo é baseada na razão de chances (AGRESTI, 2007).

$$\text{logito}[\pi(x_i)] = \log \left[\frac{\pi(x_i)}{1 - \pi(x_i)} \right] = \alpha_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} \quad (2.4.2)$$

Onde:

- $\pi(x_i)$: probabilidade de ‘sucesso’ para a observação i , na presença das variáveis explicativas $x_i = (x_{1i}, x_{2i}, \dots, x_{ki})$;
- α_0 : parâmetro que representa o intercepto;
- $\beta_1, \dots, \beta_k$: indicam os coeficientes de regressão associados às k variáveis explicativas do modelo;
- $x_i = (x_{1i}, x_{2i}, \dots, x_{ki})$: vetor da i -ésima observação das k variáveis explicativas.

Portanto, a imputação com apoio da Regressão Logística ocorreu baseada nos ajustes dos melhores modelos logísticos possíveis para cada simulação realizada. Em que a variável resposta foi a variável que apresentou dados faltantes, e tais pontos faltantes 0 e 1 foram estimados com base nas demais variáveis presente no banco de dados. Assim como na imputação pela moda, novos modelos de Regressão Linear finais foram obtidos após a imputação pelos valores gerados pelos modelos de Regressão Logística.

2.4.3 Comparação

As duas técnicas de imputação apresentadas foram comparadas conforme algumas medidas obtidas pelo modelo de Regressão Linear final ajustado para cada conjunto de dados faltantes simulado, e de acordo com a quantidade de valores acertados por cada técnica, contabilizados após a imputação.

Dessa forma, a medida utilizada para comparar as adequabilidades dos modelos finais foi o Erro Quadrático Médio (EQM). Em Regressão Linear, o EQM se refere à tendência central do erro de previsão, ou seja, fornece a média das diferenças quadráticas entre a predição do modelo e o valor real, conforme descrito na Equação 2.4.3, tratando-se da medida mais comum de comparação entre modelos e sensível na ausência de valores discrepantes (HARRELL et al., 2015)

$$EQM(\hat{y}) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i) \quad (2.4.3)$$

No caso, o EQM do modelo ideal, ajustado para o conjunto de dados sem alteração e completo, foi utilizado como fonte comparativa. Após cada técnica implementada e valores dos Erros Quadráticos Médios de previsão encontrados, para cada base de dados simuladas com dados faltantes, foram obtidas médias, variâncias e quantis (2.5% e 97.5%) para os EQMs, conforme a proporção de *missings*. Quanto menor a média e a variância dos valores dos Erros Quadráticos Médios para cada proporção, espera-se que a respectiva técnica de imputação gere modelos com melhor ajuste (KUTNER et al., 2005)

3 Resultados

3.1 Adequação do Modelo Linear

O modelo de Regressão Linear final, considerado para ajuste da previsão do tamanho da concha do caranguejo-ferradura fêmea, é completo, ou seja, apresenta todas as possíveis variáveis explicativas: peso; cor; tipo da coluna; e sinalização da presença de ao menos um caranguejo-ferradura macho nas proximidades.

Apesar da presença de dois valores atípicos, o modelo foi bem ajustado após verificar os pressupostos, e não houve necessidade da transformação de Box-Cox. Em destaque, a normalidade do erro do modelo de regressão (Figura 1) parece violada devido a presença de *outliers*, porém o teste de Kolmogorov-Smirnov retrata não rejeição da hipótese de que o resíduo apresenta distribuição normal (teste utilizado pois seu resultado não é afetado por valores atípicos, com $p\text{-valor} = 0.44$). Também quanto aos resíduos, foi verificada a homoscedasticidade (Figura 2), que por meio do teste de Breusch-Pagan atestou evidência de variância constante. Não houve indícios de violação dos demais pressupostos, e portanto os resultados do modelo foram considerados consistentes. Algumas medidas ¹ e coeficientes ² podem ser observados na Tabela 1.




Figura 1: Verificação gráfica da normalidade dos resíduos.

¹EQM: Erro Quadrático Médio; EAM: Erro Absoluto Médio.

²R2: R-quadrado; R2(aj): R-quadrado ajustado.




Figura 2: Verificação gráfica da variabilidade dos resíduos e de valores atípicos.

Tabela 1: Medidas do Modelo de Regressão Linear para os dados completos.

EQM	EAM	R2	R2(aj)
0.876851	0.6972029	0.8050759	0.7968064

3.2 Comparação das Técnicas de Imputação

Foi constatado que, para todas possíveis proporções (1%, 5%, 10%, 20% e 40%) de dados faltantes simulados, o acerto dos valores corretos para a variável que identifica a presença ou não de ao menos um caranguejo-ferradura macho nas proximidades foi maior ao utilizar a técnica de imputação por regressão. Para os percentuais de *missings* considerados, em mais de 71% das vezes a quantidade de dados recuperados pela imputação por Regressão Logística apresentou maior taxa de acerto do verdadeiro valor faltante.

Com respeito aos Erros Quadráticos Médios (EQMs) obtidos para cada modelo linear gerado, a Figura 3 retrata que a média após imputação pela Regressão Logística foi superior para todos os casos de proporções de dados faltantes, contudo, foi observado que a variabilidade dos EQMs após imputação pela Moda foi superior, com a presença de mais valores atípicos.




Figura 3: Comparação dos Erros Quadráticos Médios para diferentes proporções de dados faltantes.

Os Boxplots dos EQMs apresentados na Figura 4 exemplificam o cenário que ocorreu para as cinco proporções de dados faltantes. É possível notar a presença de mais valores discrepantes ao imputar pela Moda, e que aproximadamente 75% dos valores obtidos por Regressão Logística estão acima do valor real de EQM (Tabela 1), o que faz sentido no contexto do modelo linear apresentado. Além disso, a técnica que utiliza modelagem preditiva apresentou estabilidade e consistência nos resultados obtidos.




Figura 4: Boxplots para EQMs gerados por cada técnica, comparando duas proporções de dados faltantes (5% e 20%) simulados para a variável resposta.

Apesar da diferença aparentemente mínima, as Tabelas 2 e 3 sintetizam algumas medidas importante referentes aos Erros Quadráticos Médios de previsão. Foi verificado que para todas as proporções de dados faltantes induzidas, a média foi sempre menor após a imputação pela Moda. No entanto, a variabilidade para a técnica que utiliza Moda é maior para todos os casos, que resulta em uma maior amplitude entre os quantis 2.5% e 97.5%, quando comparada com a técnica de modelagem preditiva. Esses resultados indicam maior robustez da técnica de imputação via modelagem preditiva.

Dados faltantes	Média	Variância	Q _{2.5%}	Mediana	Q _{97.5%}
1%	0.8775	0.00009731	0.8517213	0.8808287	0.886057
5%	0.87751	0.00009740	0.8517213	0.880922	0.886057
10%	0.8775	0.00009730	0.8517213	0.8808287	0.886057
20%	0.87752	0.00009744	0.8517213	0.880922	0.886057
40%	0.87752	0.00009744	0.8517213	0.880922	0.886057

Tabela 2: Medidas dos EQMs obtidas após imputação por: MODA.

Dados faltantes	Média	Variância	Q _{2.5%}	Mediana	Q _{97.5%}
1%	0.87892	0.00003964	0.8642039	0.8803475	0.886039
5%	0.87892	0.00003964	0.8642039	0.8803475	0.886039
10%	0.87892	0.00003963	0.8642039	0.8803475	0.886039
20%	0.87893	0.00003962	0.8642039	0.8803475	0.886039
40%	0.87894	0.00003969	0.8642039	0.8803953	0.886039

Tabela 3: Medidas dos EQMs obtidas após imputação por: REGRESSÃO LOGÍSTICA.

4 Discussão

A base de dados reais utilizada para retratar diferenças entre as técnicas citadas apresentou resultados aparentemente parecidos ao comparar valores dos Erros Quadráticos Médios obtidos após simulações. É possível que isso tenha ocorrido pelo fato da variável utilizada para imputação ser pouco significativa para o modelo final ajustado. No entanto, o ajuste do modelo linear, capaz de estimar o tamanho da concha do caranguejo-ferradura fêmea, mostrou-se em escala e graficamente mais eficaz ao utilizar a imputação por modelagem preditiva.

Como mencionado, a variável utilizada como ilustração para a implementação das

técnicas representa a existência ou não de ao menos um caranguejo-ferradura macho nas proximidades. A importância da recuperação desses dados não está relacionada apenas com a implementação do melhor modelo capaz de estimar o tamanho do animal, mas também com a possibilidade de localizá-los (VAUTHIER, 2021).

Pesquisas sobre os crustáceos caranguejos-ferradura ganharam força nos últimos anos, em principal devido ao desenvolvimento de vacinas. A hipersensibilidade do seu sangue para endotoxinas bacterianas é usada para testar a contaminação em indústrias farmacêuticas, fábricas de dispositivos médicos, centros de pesquisa e hospitais. Neste contexto, a demanda de instituições pelo animal caranguejo-ferradura aumentou consideravelmente (GORMAN, 2020; BRASIL, 2020).

5 Conclusão

Todos os resultados obtidos de comparação entre as duas técnicas apresentadas mostraram que a imputação de dados dicotômicos com a utilização de Regressão Logística foi, de fato, mais eficiente, quando comparada com a imputação pela estatística de tendência central Moda. Apesar de haver pouca diferença nítida entre as medidas obtidas, a variabilidade dos resultados ao usar a imputação pela Moda foi superior, fator que aponta menor robustez para a técnica, em especial para proporções elevadas de dados faltantes.

Referências

- AGRESTI, A. *An introduction to categorical data analysis*. 2nd. ed. [S.l.]: John Wiley & Sons, 2007. 372 p.
- AMBLER, G.; OMAR, R. Z.; ROYSTON, P. A comparison of imputation techniques for handling missing predictor values in a risk model with a binary outcome. *Statistical methods in medical research*, Sage Publications Sage UK: London, England, v. 16, n. 3, p. 277–298, 2007.
- BRASIL, B. N. O sangue azul de caranguejo que salva milhões de vidas todos os anos. 2020.
- BROCKMANN, H. J. Satellite male groups in horseshoe crabs, *limulus polyphemus*. *Ethology*, Wiley Online Library, v. 102, n. 1, p. 1–21, 1996.
- BUCK, S. F. A method of estimation of missing values in multivariate data suitable for use with an electronic computer. *Journal of the Royal Statistical Society: Series B (Methodological)*, Wiley Online Library, v. 22, n. 2, p. 302–306, 1960.
- GORMAN, R. Horseshoe crabs and the pharmaceutical industry: Challenges and alternatives. University of Exeter, 2020.
- HARRELL, F. E. et al. *Regression modeling strategies: with applications to linear models, logistic and ordinal regression, and survival analysis*. [S.l.]: Springer, 2015. v. 3.
- KENWARD, M. G.; CARPENTER, J. Multiple imputation: current perspectives. *Statistical methods in medical research*, Sage Publications Sage UK: London, England, v. 16, n. 3, p. 199–218, 2007.
- KUTNER, M. H. et al. *Applied linear statistical models*. [S.l.]: McGraw-Hill New York, 2005.
- MCKNIGHT, P. E. et al. *Missing data: A gentle introduction*. [S.l.]: Guilford Press, 2007.
- NUNES, L. N. Métodos de imputação de dados aplicados na área da saúde. Tese de Doutorado (programa de Pós-Graduação em Epidemiologia), Universidade Federal do Rio Grande do Sul, 2007.
- PROVOST, F.; FAWCETT, T. Data science and its relationship to big data and data-driven decision making. *Big data*, Mary Ann Liebert, Inc. 140 Huguenot Street, 3rd Floor New Rochelle, NY 10801 USA, v. 1, n. 1, p. 51–59, 2013.
- RODRIGUES, S. C. A. *Modelo de regressão linear e suas aplicações*. Tese (Doutorado) — Universidade da Beira Interior, 2012.
- RUBIN, D. B. Multiple imputation after 18+ years. *Journal of the American statistical Association*, Taylor & Francis, v. 91, n. 434, p. 473–489, 1996.
- VAUTHIER, D. Horseshoe crabs, covid-19, and climate change: How everything is connected. 2021.