



Técnicas de Imputação para Variáveis Dicotômicas

Enzo Porto Brasil

Orientador: Prof. Dr. Eduardo Y. Nakano

01 de Setembro de 2022

- Acesso a mais informação nos últimos anos.
- Valores faltantes são recorrentes em bancos de dados.
- Estatística é fundamentada para analisar bases de dados completas.

Introdução

O que é **imputação** de dados?

Como se aplica para **variáveis dicotômicas**?

Base de dados inicial

ID	Idade	Estudante
1	25	Sim
2	31	
3	27	Não
4	22	Não
5	29	

← Variável dicotômica

← Dados faltantes

Técnica de imputação

- Regressão Logística
- Moda

Após imputação

ID	Idade	Estudante
1	25	Sim
2	31	Sim
3	27	Não
4	22	Não
5	29	Sim

Objetivos

- Investigar a importância das principais técnicas de imputação de dados faltantes dicotômicos;
- Exemplificar a relevância da recuperação de informações em um contexto real;
- Destacar possíveis diferenças entre as técnicas de imputação (moda e Regressão Logística).

- Referente ao animal caranguejo-ferradura, que apresenta as seguintes informações sobre cada fêmea estudada: coloração, condição da coluna, tamanho da concha e peso. Além disso, a base contém a quantidade de caranguejos machos encontrados nas proximidades.
- A variável de interesse estudada neste trabalho indica se existe ou não ao menos um caranguejo macho encontrado próximo da fêmea.
- Não apresenta dados faltantes.



- Regressão Linear Múltipla: construção de um modelo capaz de estimar o tamanho da concha do caranguejo-ferradura fêmea, com base nas demais características que ela apresenta.
- Variável resposta com natureza quantitativa contínua.

Os dados faltantes foram gerados de forma aleatória, e esse processo foi simulado 400 vezes.



Para fins de comparação, cinco diferentes proporções de dados faltantes foram consideradas na análise, sendo elas: 1%, 5%, 10%, 20% e 40%



Para cada base um modelo de Regressão Linear foi obtido e ajustado.



Totalizando 2000 bases de dados simuladas com a presença de dados faltantes hipotéticos.



Em cada situação as duas técnicas de imputação foram utilizadas para comparação.

Moda e Regressão Logística

Moda

- Depende apenas da variável que apresenta os valores faltantes;
- Foi imputado o valor que aparece com mais frequência.

X

Regressão Logística

- Depende de uma ou mais variável do conjunto de dados;
- Técnica de modelagem preditiva, usada para prever dados de variáveis com resposta dicotômica (0 ou 1);
- Ajuste de bons modelos logísticos para cada simulação realizada, e assim imputar os *missings*.

Os modelos de Regressão Linear finais foram ajustados com a presença dos valores imputados pelas técnicas para a variável que indica a presença ou não de ao menos um caranguejo macho nas proximidades.

- Quantidade de valores acertados por cada técnica de imputação.
- Medidas obtidas pelo modelo de Regressão Linear final ajustado para cada conjunto de dados faltantes simulado, com base no **Erro Quadrático Médio (EQM)** de previsão.



Foram obtidas médias, variâncias e quantis (2.5% e 97.5%) para os EQMs, conforme cada proporção de *missings*.


Quanto menor a média e a variância dos valores EQMs para cada proporção, espera-se que a respectiva técnica de imputação gere modelos com melhor ajuste.

Resultados

Adequação do Modelo Linear

- Estimativa do tamanho da concha do caranguejo-ferradura fêmea;
- Modelo completo e bem ajustado.

EQM	R ²
0.877	0.805



Resultados

Comparação entre Técnicas: **Taxa de Acerto**

- Em mais de 71% das ocasiões simuladas, para todas as proporções de *missings*, a quantidade de dados recuperados com uso de Regressão Logística apresentou maior taxa de acerto do valor verdadeiro.



Variável explicativa: indica se existe ou não ao menos um caranguejo macho encontrado nas proximidades.







Resultados EQM's

Regressão Logística

- Média maior;
- Menor variabilidade.

Moda

- Média pouco menor;
- Maior variabilidade.



Resultados
EQM's

- **Maior robustez** para o ajuste do modelo final após imputação por **Regressão**.

Imputação pela Moda 15/15

Dados faltantes	Média	Variância	Q _{2.5%}	Mediana	Q _{97.5%}
1%	0.8775	0.00009731	0.8517213	0.8808287	0.886057
5%	0.87751	0.00009740	0.8517213	0.880922	0.886057
10%	0.8775	0.00009730	0.8517213	0.8808287	0.886057
20%	0.87752	0.00009744	0.8517213	0.880922	0.886057
40%	0.87752	0.00009744	0.8517213	0.880922	0.886057

Imputação por Regressão Logística

Dados faltantes	Média	Variância	Q _{2.5%}	Mediana	Q _{97.5%}
1%	0.87892	0.00003964	0.8642039	0.8803475	0.886039
5%	0.87892	0.00003964	0.8642039	0.8803475	0.886039
10%	0.87892	0.00003963	0.8642039	0.8803475	0.886039
20%	0.87893	0.00003962	0.8642039	0.8803475	0.886039
40%	0.87894	0.00003969	0.8642039	0.8803953	0.886039

Conclusão

- Mais eficiência e consistência dos dados após imputação com uso de Regressão Logística;
- Apesar de haver pouca diferença nítida entre as medidas obtidas, a variabilidade ao imputar pela Moda foi superior para todos os casos;
- Foi constatado menor robustez para a técnica de imputação pela Moda, em especial para proporções elevadas de dados faltantes.

Principais referências

AGRESTI, A. **An introduction to categorical data analysis**. 2nd ed. New Jersey: Jhon Wiley Sons, Inc., 2007, 372 p.

AMBLER, G. et al. **A comparison of imputation techniques for handling missing predictor values in a risk model with a binary outcome**. Statistical Methods in Medical Research, 16(3): 277-298, 2007.

BUUREN, S. **Flexible Imputation of Missing Data**. 2nd ed. Chapman Hall/CRC, 2018.

HARREL, F. E. Jr. **Regression modeling strategies: with applications to linear models, logistic and ordinal regression, and survival analysis**. 2nd ed. Springer -Verlag, 2015.

KUTNER, M. et al. **Applied linear statistical models**. 5th ed. New York: McGrawHill/Irwin, 2005. 1415 p.

NUNES, L. N. **Métodos de imputação de dados aplicados na área de saúde**. 2007. 120 f.. Tese (Doutorado em Epidemiologia) - Faculdade de Medicina, Universidade Federal do Rio Grande do Sul, Porto Alegre, set. 2007.