



Autor bolsista do Conselho Nacional de Desenvolvimento Científico e Tecnológico - CNPq. Processo 131782/2024-0



Departamento de Estatística  
Universidade de Brasília

Link para o trabalho completo em:  
<https://bdm.unb.br/handle/10483/38509>

# Evaluating imputation strategies for missing data through statistical modeling and simulations

Enzo Porto Brasil<sup>1</sup> & Eduardo Yoshio Nakano<sup>2</sup>

<sup>1</sup>enzoporto2000@gmail.com, <sup>2</sup>nakano@unb.br

## Introdução

No século 21, os dados se consolidaram como um dos objetos de estudo mais valiosos na ciência. Porém, a perda de informações e a ocorrência de dados faltantes são problemas recorrentes em levantamentos de pesquisas, o que pode gerar análises tendenciosas. Com a metodologia estatística é fundamentada para avaliar dados completos, é necessário adotar estratégias eficazes de tratamento para garantir resultados robustos e precisos.

Este trabalho teve sobretudo o objetivo de analisar as principais técnicas de imputação de dados faltantes com base em modelagem estatística, e relatar a importância de tais métodos para diferentes cenários. A escolha do modelo adequado para cada imputação ocorreu de acordo com a sua capacidade preditiva e a natureza da variável a ser imputada. Foi requisito para o estudo analisar apenas bases compostas por dados faltantes gerados por fator aleatório. Também foram explorados conceitos pouco divulgados relacionados à área de imputação, com elaboração de um guia prático e possíveis sugestões para futuras pesquisas relacionadas ao tema.

## 1 Materiais e Métodos

A pesquisa foi dividida em três partes principais de aplicação. Essas partes foram subdivididas em situações que envolvem tanto imputações únicas, quanto imputações múltiplas. O foco maior está em representar possíveis soluções ou algoritmos para cenários recorrentes de dados faltantes, com demonstração em um único conjunto de dados simulados, apresentando métodos de simples a complexos. Toda a análise foi fomentada com uso do software R versão 4.3.2.

- **Parte 1:** imputação única em cenário simples;
- **Parte 2:** comparação direta da imputação única com uso apenas de modelagem preditiva em um cenário mais complexo (mais de uma variável com dados faltantes); e
- **Parte 3:** imputação múltipla simultânea.

Em todos os cenários abordados, a pesquisa foi direcionada frente: ao mesmo banco de dados original e completo; às mesmas bases com dados faltantes simulados; e ao mesmo modelo de regressão linear final para comparação das técnicas de imputação, ou seja, preservando as mesmas covariáveis independentes da técnica utilizada.

### Banco de dados simulados

Composto por 200 observações e 6 variáveis caracterizadas por  $y$ ,  $x_1$ ,  $x_2$ ,  $x_3$ ,  $x_4$  e  $x_5$ . Cada variável apresenta uma distribuição pré definida, a fim de explorar técnicas de imputação aplicadas em diferentes cenários e naturezas de variáveis.

### Modelo preditivo final

- Regressão linear:  $Y \sim X_1 + X_2 + X_3 + X_4 + X_5$ ;
- Todas as suposições atendidas e consistentes;
- Medidas obtidas para o modelo ajustado aos dados completos: Erro Quadrático Médio (EQM = 11.256) e Coeficiente de Determinação ( $R^2 = 0.936$ ).

### Simulação de dados faltantes

Gerar bases com diferentes proporções de dados faltantes em certas variáveis (1%, 5%, 10%, 20% e 40%). Obter 300 bases de dados simuladas para cada proporção (total de 1500 bases de dados para cada técnica). Propor diferentes cenários de estudo e aplicações.

### Comparação entre técnicas

As técnicas foram comparadas com base em diagnósticos dos modelos ajustados aos dados após as imputações (EQM e R-quadrado): estatísticas descritivas (média, variância e quartis); boxplots e curvas de densidade; e testes de hipótese para comparação de amostras.

## 2 Principais resultados




Figura 1: Boxplots referentes aos EQMs obtidos nos cenários 1 e 2 de imputação única, conforme cada técnica utilizada para imputar valores de  $x_5$ . De acordo também com três proporções de dados faltantes simulados para a variável  $x_5$ .




Figura 2: Boxplots referentes aos EQMs obtidos nos cenários 1 a 4, para representação de resultados de técnicas com uso, apenas, de modelos de regressão linear para imputar valores de  $x_5$ . Com representação de quatro proporções de dados faltantes simulados para a variável  $x_5$ .

## 3 Discussão e Considerações Finais

- Os resultados apontaram destaque para a imputação múltipla simultânea;
- A imputação única com a técnica correta foi suficiente para casos com baixa quantidade de dados faltantes;
- Além disso foi constatado que desconsiderar dados faltantes das análises gerou os piores resultados para os ajustes dos modelos finais;
- Foram observados três principais fatores de influência no desempenho das técnicas: quantidade de dados faltantes, número de variáveis incompletas e natureza de tais variáveis;
- Frente à literatura e aos resultados deste trabalho, um guia prático foi documentado, a fim de auxiliar pesquisadores quanto ao tratamento de bases incompletas. Também é sugerido para trabalhos futuros explorar novos cenários e técnicas com orientações cada vez mais especializadas.

## Referências

- [1] Frank E Harrell et al. *Regression modeling strategies: with applications to linear models, logistic and ordinal regression, and survival analysis*, volume 3. Springer, 2015.
- [2] Michael G Kenward and James Carpenter. Multiple imputation: current perspectives. *Statistical methods in medical research*, 16(3):199–218, 2007.
- [3] Luciana Neves Nunes. Métodos de imputação de dados aplicados na área da saúde. 2007.
- [4] Foster Provost and Tom Fawcett. Data science and its relationship to big data and data-driven decision making. *Big data*, 1(1):51–59, 2013.
- [5] Stef Van Buuren. *Flexible imputation of missing data*. CRC press, 2018.